

Politechnika Rzeszowska im. Ignacego Łukasiewicza

Wydział Matematyki i Fizyki Stosowanej



**WYDZIAŁ
MATEMATYKI
I FIZYKI STOSOWANEJ**
POLITECHNIKI RZESZOWSKIEJ

**Wielowymiarowa analiza danych – zarządzania światową
bazą danych sprzedaży**

Mateusz Gałda, Paweł Górski

FSO-DI

Rzeszów 2026

Spis treści

1	Cel projektu	4
2	Baza danych Sales records.....	4
3	Realizacja i wdrożenie projektu	5
3.1	Import danych do środowiska Microsoft SQL Server	5
3.2	Proces automatyzacji importu danych	7
3.3	Stworzenie architektury gwiazdy.....	11
4	Scenariusze KPI.....	16
4.1	Najbardziej zyskowe Regiony i Kraje	16
4.2	Ranking Produktów (Asortyment).....	18
4.3	Analiza Kanałów Sprzedaży (Online vs Offline)	19
4.4	Miesięczny Trend Sprzedaży (Time Series).....	20
5	Wizualizacje procesów KPI	20
5.1	Globalny kokpit rentowności geograficznej i dystrybucyjnej	21
5.2	Analiza przyrostu marży asortymentowej (Wykres kaskadowy)	22
5.3	Wielopoziomowy trend czasowy przychodów z hierarchią dat	22
5.4	Wykres punktowy pozycjonowania produktów.....	25
5.5	Efektywność operacyjna kanałów dystrybucji	26
6	Eksploracja danych Data Mining	27
6.1	Projektowanie wielowymiarowej kostki analitycznej (OLAP).....	28
6.2	Algorytm drzewa decyzyjnego	29
6.3	Predykcja finansowa z wykorzystaniem algorytmu szeregów czasowych.....	32
6.4	Segmentacja danych z wykorzystaniem algorytmu klastrowania	34
6.5	Modelowanie probabilistyczne z wykorzystaniem algorytmu Naive Bayes	39
6.6	Dodatkowe wizualizacje procesów data mining w Power BI.....	41
6.6.1	Identyfikacja czynników decydujących o rentowności	41
6.6.2	Wielowymiarowa analiza przyczynowo-skutkowa	42
7	Kierunki dalszego rozwoju systemu	42
8	Podsumowanie	43

1 Cel projektu

Głównym celem projektu jest zaprojektowanie i wdrożenie kompleksowego rozwiązania klasy Business Intelligence (BI), które przekształca surowe dane transakcyjne w użyteczną wiedzę biznesową wspierającą procesy decyzyjne w przedsiębiorstwie. Architektura systemu opiera się na pełnej integracji technologii analitycznych firmy Microsoft. Warstwa przechowywania danych została zrealizowana w środowisku Microsoft SQL Server, gdzie zaimplementowano relacyjną strukturę hurtowni danych w oparciu o optymalny schemat gwiazdy (integrujący tabele faktów i wymiarów). Procesy zasilania hurtowni, przekształcania danych (ETL) oraz zaawansowane modelowanie analityczne zostały zaprojektowane i wdrożone w środowisku Visual Studio 2019 przy użyciu pakietu narzędziowego SQL Server Data Tools (SSDT) – w tym usług integracyjnych (SSIS) oraz analitycznych (SSAS). Zwieńczeniem architektury jest warstwa analityczno-wizualna zaimplementowana w środowisku **Power BI**, pełniąca rolę interfejsu końcowego.

Realizacja projektu w obszarze prezentacji i analizy danych została podzielona na dwa kluczowe komponenty. Pierwszym z nich jest analityka zarządcza (KPI), w ramach której stworzono w pełni interaktywny kokpit menedżerski pozwalający na dynamiczne filtrowanie krzyżowe danych m.in. z wykorzystaniem interaktywnej mapy globalnej rentowności, wykresów kaskadowych oraz pierścieniowych. Drugim, wysoce zaawansowanym obszarem jest eksploracja danych (Data Mining), w której wykorzystano zasilane z kostki analitycznej algorytmy sztucznej inteligencji Power BI takie jak Drzewo Dekompozycji czy detekcja Kluczowych Czynników Wpływających. Ich zastosowanie ma na celu automatyczną identyfikację ukrytych korelacji w wielowymiarowych strukturach danych, segmentację produktów ze względu na marżowość oraz przeprowadzenie zaawansowanej analizy przyczynowo-skutkowej, co w ujęciu całościowym pozwala nie tylko na monitorowanie przeszłych wyników, ale przede wszystkim na zrozumienie czynników napędzających zysk z sprzedaży poszczególnych produktów.

2 Baza danych Sales records

Dane wykorzystane w niniejszym projekcie pochodzą z platformy Kaggle, z publicznego repozytorium nazwą „1000000 Sales Records - Excel BI Analytics”. Zbiór, dostępny pod adresem <https://www.kaggle.com/datasets/ishansurana1234/1000000-sales-records-excel-bi-analytics>, ma format pliku CSV. Zgodnie z oryginalną dokumentacją twórcy zestawienia, jest

to wygenerowana baza transakcyjna zawierająca dokładnie jeden milion rekordów sprzedażowych. Charakteryzuje się ona wyjątkowo rozległym zakresem czasowym, ponieważ ujęte w niej operacje handlowe rozciągają się na przestrzeni 46 lat, obejmując okres od 1972 do 2022 roku. Zbiór ten został stworzony specjalnie jako baza testowa dedykowana do ćwiczeń analitycznych z użyciem programu Excel oraz zaawansowanych systemów klasy Business Intelligence.


Oryginalna tabela źródłowa składa się z kilkunastu kolumn odwzorowujących procesy sprzedaży

o zasięgu globalnym. Znajdują się w niej atrybuty lokalizacyjne, takie jak region i kraj, oraz atrybuty operacyjne określające kategorię produktu (Item Type), kanał sprzedaży (Sales Channel z podziałem na Online i Offline) i priorytet zamówienia. Ponadto baza zawiera dane czasowe i identyfikacyjne, w tym datę wpłynięcia zamówienia (Order Date), datę wysyłki (Ship Date) oraz unikalny identyfikator transakcji (Order ID). Kluczowym elementem zestawienia są miary ilościowe i finansowe: liczba sprzedanych sztuk, cena jednostkowa oraz koszt jednostkowy. Na podstawie tych trzech wartości, w zbiorze znajdują się również z góry wyliczone wartości sumaryczne obejmujące całkowity przychód (Total Revenue), całkowity koszt (Total Cost) oraz całkowity zysk z danej transakcji (Total Profit).

3 Realizacja i wdrożenie projektu

3.1 Import danych do środowiska Microsoft SQL Server

Proces budowy hurtowni danych rozpoczyna się w środowisku SQL Server Management Studio od zdefiniowania odpowiednich struktur tabelarycznych przy użyciu języka zapytań SQL. W pierwszej kolejności tworzona jest płaska, zdenormalizowana tabela o nazwie sales_records, która pełni rolę obszaru przejściowego dla surowych danych pobranych z pliku. Następnie, zgodnie z założeniami optymalnego schematu gwiazdy, projektowane są tabele słownikowe, czyli wymiary. Należą do nich tabela dim_Location, przechowująca unikalne informacje geograficzne o regionach i krajach, oraz tabela dim_Item, definiująca kategorie sprzedawanych produktów. Całą architekturę spaja centralna tabela faktów o nazwie fact_Sales, która gromadzi miary ilościowe i finansowe oraz klucze obce pozwalające na relacyjne powiązanie transakcji z odpowiednimi wymiarami.



Rysunek 1 Struktura bazy danych

```

-- Tabela z typami produktów
CREATE TABLE dim_Item (
    Item_ID INT IDENTITY(1,1) PRIMARY KEY,
    Item_Type VARCHAR(100)
);

-- Główna tabela sprzedażowa
CREATE TABLE fact_Sales (
    Order_ID INT PRIMARY KEY,
    Location_ID INT,
    Item_ID INT,
    Sales_Channel VARCHAR(50),
    Order_Priority CHAR(1),
    Order_Date DATE,
    Ship_Date DATE,
    Units_Sold INT,
    Unit_Price DECIMAL(10, 2),
    Unit_Cost DECIMAL(10, 2),
    Total_Revenue DECIMAL(10, 2),
    Total_Cost DECIMAL(10, 2),
    Total_Profit DECIMAL(10, 2)
);

```


Rysunek 2 Struktura bazy danych

- **sales_records** (tabela pomocnicza) – służy jako "brudnopis". Jej zadaniem jest szybkie i bezpieczne przyjęcie całego miliona rekordów prosto z pliku, chroniąc docelową bazę przed błędami i zacięciami podczas importu.
- **dim_Location** (słownik lokalizacji) – służy do przechowywania nazw krajów i regionów. Dzięki niej nazwy państw nie powtarzają się milion razy, co mocno oszczędza miejsce na dysku i przyspiesza wczytywanie map w raportach.
- **dim_Item** (słownik produktów) – służy do uporządkowania asortymentu. Pozwala to systemowi na błyskawiczne grupowanie wyników.

- **fact_Sales** (główna tabela faktów) – to serce całej bazy. Przechowuje wyłącznie czyste dane liczbowe (sprzedane sztuki, koszty, zyski) podpisane pod słownikami. Stworzono ją po to, aby Power BI mógł efektywniej analizować finanse z miliona transakcji.


3.2 Proces automatyzacji importu danych

Proces automatyzacji importu danych został zrealizowany w środowisku Visual Studio z wykorzystaniem pakietów SQL Server Integration Services (SSIS). Pierwszym etapem prac w obszarze przepływu danych było skonfigurowanie połączenia ze źródłowym plikiem tekstowym. W tym celu wykorzystano komponent Flat File Connection Manager. W jego oknie konfiguracyjnym wskazano dokładną ścieżkę do pliku CSV, który zawierał wygenerowane rekordy sprzedażowe. Niezwykle ważnym krokiem na tym etapie było zdefiniowanie odpowiedniej strony kodowej, wybrano kodowanie 1250 dedykowane dla Europy Środkowej, co gwarantuje poprawne odczytanie wszystkich znaków. Dodatkowo w konfiguracji określono format pliku jako rozdzielany znakami (Delimited) oraz zdefiniowano znacznik końca wiersza. Pozwala to algorytmom SSIS na prawidłowe zinterpretowanie płaskiego tekstu i podzielenie go na ustrukturyzowane kolumny oraz wiersze gotowe do dalszego przetwarzania



Rysunek 3 Import danych


Po pomyślnym zdefiniowaniu źródła danych, kolejnym krokiem było ustanowienie bezpiecznego i stabilnego połączenia z docelową bazą danych, do której miały trafić informacje. Do tego zadania użyto menedżera połączeń OLE DB. W panelu konfiguracyjnym wskazano nazwy lokalnego serwera bazodanowego oraz wybrano z listy docelową bazę o nazwie HurtowniaSprzedazy. Uwierzytelnienie zrealizowano przy pomocy zintegrowanych zabezpieczeń systemu Windows, oznaczonych jako SSPI. Taka konfiguracja zapewnia tworzonemu pakietowi ETL niezbędne, autoryzowane uprawnienia do wstawiania i modyfikowania rekordów bezpośrednio w strukturach Microsoft SQL Server.



Rysunek 4 Połączenie z Microsoft server

Kluczowym momentem procesu budowy przepływu danych było precyzyjne zmapowanie kolumn pomiędzy zdefiniowanym wcześniej źródłem a miejscem docelowym. Operację tę przeprowadzono w oknie edytora docelowego OLE DB, w dedykowanej zakładce mapowań. Skonfigurowano tam powiązania struktury wejściowej pochodzącej z pliku CSV z odpowiadającymi im polami w utworzonej wcześniej relacyjnej tabeli pomocniczej w bazie SQL. Proces ten polega na ścisłym, logicznym dopasowaniu kolumn wejściowych do kolumn docelowych. Jest to krok absolutnie niezbędny do tego, aby silnik bazy danych wiedział, do

którego dokładnie miejsca ma przetransferować konkretną wartość, zapewniając tym samym pełną spójność importowanych danych z zaprojektowanym modelem tabeli.




Rysunek 5 Mapowanie kolumn


Zwieńczeniem całego etapu było uruchomienie zaprojektowanego pakietu w celu wykonania fizycznego transferu informacji. Wewnątrz widoku przepływu danych strumień rekordów został skierowany ze źródła pliku płaskiego bezpośrednio do docelowego komponentu bazodanowego. Środowisko Visual Studio w czasie rzeczywistym monitorowało przebieg tej obciążającej operacji. Pomyślne i bezbłędne zakończenie całego procesu migracji zostało zasygnalizowane pojawieniem się zielonych znaczników weryfikacyjnych przy poszczególnych komponentach na ekranie projektowym.

Kluczowym elementem podnoszącym niezawodność całego procesu ETL było wdrożenie warstwy walidacji danych, opartej na transformacji rozdzielania warunkowego (Conditional Split). Komponent ten posłużył do dokładnej weryfikacji braków danych w strumieniu wejściowym przed ich ostatecznym zapisaniem w bazie. W konfiguracji narzędzia zastosowano wyrażenie logiczne `!ISNULL([Sales_Channel]) && [Sales_Channel] != ''`. Warunek ten sprawdzał, czy kluczowe pole nie

jest wartością pustą (NULL) oraz czy nie zawiera pustego ciągu znaków. Rekordy, które posiadały braki danych, zostały automatycznie odseparowane i przekierowane do wyjścia domyślnego. Dzięki temu skutecznie zabezpieczono docelową bazę przed zapisaniem niekompletnych rekordów, co zapewniło spójność i poprawność struktur całej hurtowni danych.



Rysunek 6 Oczyszczanie danych




Rysunek 7 Import danych


3.3 Stworzenie architektury gwiazdy

Podział danych na tabele wymiarów oraz tabelę faktów opiera się na klasycznym modelu organizacji struktur hurtowni danych, zwanym architekturą gwiazdy (Star Schema). Nazwa tej architektury wynika ze specyficznego kształtu relacji: w samym centrum znajduje się jedna duża tabela faktów, a wokół niej rozłożone są mniejsze tabele wymiarów, przypominające ramiona gwiazdy. Głównym celem stosowania tego podejścia jest uproszczenie struktury bazy danych, skrócenie czasu wykonywania zapytań raportowych oraz eliminacja redundancji, czyli powtarzania się tych samych bloków tekstu w milionach wierszy tabeli operacyjnej.

Fizyczny proces podziału płaskiej struktury rekordów na niezależne tabele zrealizowano wewnątrz zaprojektowanego pakietu ETL. Pierwszym etapem było zasilenie tabeli wymiaru lokalizacji (dim_locations), która odpowiada za kontekst przestrzenny i geograficzny analizy. Za pomocą dedykowanego komponentu odszukiwania (Lookup) system weryfikował unikalne kombinacje danych, takich jak regiony oraz powiązane z nimi kraje. Zamiast powtarzać pełne nazwy geograficzne przy każdej transakcji, tekst wpisywany jest tylko raz do tabeli słownikowej, gdzie każdy unikalny punkt otrzymuje krótki identyfikator numeryczny.




Rysunek 8 Proces data flow




Rysunek 9 Mapowanie kolumn

Równolegle realizowany był proces zasilania wymiaru produktów (dim_items), odpowiadającego za kontekst asortymentowy hurtowni. Strumień danych wejściowych został poddany identycznej weryfikacji w celu wyodrębnienia unikalnych typów produktów oraz przypisanych do nich kanałów sprzedaży. Mechanizm ten zapewnił ujednolicenie listy

towarowej i pozwolił na sprawne segmentowanie wyników finansowych, eliminując ryzyko powstawania niespójności w nazewnictwie asortymentu.




Rysunek 10 Proces data flow




Rysunek 11 Mapowanie kolumn


Ostatnim elementem tego procesu było stworzenie głównej tabeli faktów (Fact_sales), stanowiącej centralny punkt całego modelu relacyjnego. Tabela ta integruje klucze techniczne wygenerowane na etapach zasilania słowników dim_locations oraz dim_items, które pełnią funkcję kluczy obcych (łączników). Po poprawnym zmapowaniu tych identyfikatorów, do tabeli faktów trafiały bezpośrednie miary numeryczne i dane transakcyjne, takie jak liczba sprzedanych sztuk (Units_Sold), cena jednostkowa, koszty oraz wygenerowany zysk (Total_Profit).




Rysunek 12 Proces data flow



Rysunek 13 Mapowanie kolumn lookup



Rysunek 14 Mapowanie kolumn lookup




4 Scenariusze KPI

Wdrożenie struktur hurtowni danych oraz powiązanych z nimi tabel raportowych stanowi fundament do budowy zaawansowanych systemów wspomagania decyzji. Sercem takich systemów są Kluczowe Wskaźniki Efektywności (KPI – Key Performance Indicators), czyli mierzalne wskaźniki służące do ilościowej oceny stopnia realizacji celów operacyjnych i strategicznych przedsiębiorstwa. W kontekście systemów Business Intelligence, scenariusze KPI pełnią funkcję filtra interpretacyjnego, który przekształca surowe dane transakcyjne (takie jak wolumen sprzedaży czy zysk) w jednoznaczne sygnały biznesowe. Zamiast analizować rozbudowane tabele zawierające miliony rekordów, kadra zarządzająca otrzymuje bezpośrednią informację o statusie danego procesu w odniesieniu do założonych planów, norm lub historycznych punktów odniesienia. Głównym celem projektowania scenariuszy KPI jest automatyzacja procesu monitorowania kondycji przedsiębiorstwa oraz maksymalne skrócenie czasu reakcji na zachodzące zmiany rynkowe.

4.1 Najbardziej zyskowe Regiony i Kraje


Zadaniem tego procesu jest precyzyjne zidentyfikowanie regionów i krajów, które stanowią główne źródło dochodów dla przedsiębiorstwa. Dzięki temu możliwe będzie podjęcie strategicznych decyzji o alokacji budżetu marketingowego w najbardziej perspektywicznych rynkach. Proces Grupuje dane po kolumnach Region i Country, a następnie sumuje Total_Profit oraz Total_Revenue. Efektem będzie podsumowanie dla każdego kraju



Rysunek 16 SQL Query

4.2 Ranking Produktów (Asortyment)


Ten etap ma na celu wyłonienie liderów sprzedaży poprzez zestawienie wolumenu sprzedanych sztuk z ich realnym wpływem na wynik finansowy firmy. Analiza pozwoli odróżnić produkty generujące masowy obrót od tych, które dostarczają najwyższą marżę jednostkową. Proces grupuje dane po kolumnie Item_Type, sumuje Units_Sold i sumuje Total_Profit. Efektem będzie tabelka (kilkanaście wierszy), która idealnie nada się na wykres kołowy lub słupkowy.



Rysunek 17 SQL Query

4.3 Analiza Kanałów Sprzedaży (Online vs Offline)


Głównym zamierzeniem jest ewaluacja efektywności poszczególnych ścieżek dotarcia do klienta w kontekście priorytetów realizowanych zamówień. Wyniki wskażą, który kanał dystrybucji najlepiej radzi sobie z obsługą krytycznych transakcji pod kątem rentowności. Proces grupuje dane po Sales_Channel i Order_Priority, licząc średni zysk (AVG(Total_Profit)) i sumę sprzedanych sztuk. Proces będzie pokazywał, czy np. zamówienia pilne (Priority 'H') w kanale Online dają nam większy zysk niż w Offline



Rysunek 17 SQL Query

4.4 Miesięczny Trend Sprzedaży (Time Series)

Proces koncentruje się na przekształceniu rozproszonych danych historycznych w uporządkowany ciąg chronologiczny, obnażający sezonowość i dynamikę wzrostu. Tak przygotowany fundament jest niezbędny do wytrenowania modeli predykcyjnych, które z dużą dokładnością oszacują przyszłe wpływy do budżetu. Proces wyciąga Rok i Miesiąc z kolumny Order_Date i sumuje Total_Revenue dla każdego miesiąca. Efektem będzie tabela z historią sprzedaży miesiąc po miesiącu, gotowa do wrzucenia w algorytm prognozujący.



Rysunek 18 SQL Query

5 Wizualizacje procesów KPI

Bardzo ważnym etapem budowy systemu Business Intelligence było stworzenie warstwy wizualnej w środowisku Power BI, pełniącej rolę interfejsu. Przygotowany kokpit cechuje się pełną interaktywnością oraz zastosowaniem filtrowania krzyżowego, co pozwala na natychmiastowe dostosowanie prezentowanych metryk do wybranego segmentu rynku. Poniżej


przedstawiono szczegółowy opis zaimplementowanych komponentów wizualnych realizujących zdefiniowane wcześniej scenariusze KPI.

5.1 Globalny kokpit rentowności geograficznej i dystrybucyjnej

Pierwszy panel raportu integruje dynamiczne karty KPI, wykres pierścieniowy oraz interaktywną mapę globalną. Centralnym elementem jest wizualizacja kartograficzna, za pomocą której można wybierać kraje do dalszej analizy. Poszczególne regiony są zaznaczone różnymi kolorami na mapie. Po lewej stronie kokpitu umieszczono filtry i wskaźniki podsumowujące dla wybranego państwa, które w czasie rzeczywistym prezentują trzy kluczowe metryki:

- **Całkowity zysk,**
- **Marża procentowa,**
- **Całkowity przychód**

Poniżej kart KPI znajduje się wykres pierścieniowy przedstawiający ilość sprzedanych elementów wg kanałów sprzedaży. Wizualizacja ta obrazuje globalną strukturę dystrybucji wolumenu produktów pomiędzy sprzedażą online oraz offline.




Rysunek 19 Wizualizacja światowa

5.2 Analiza przyrostu marży asortymentowej (Wykres kaskadowy)

Do zobrazowania struktury generowania zysku przez poszczególne kategorie produktów wykorzystano wykres kaskadowy (Waterfall Chart). Wizualizacja ta w sposób narastający prezentuje wpływ każdego typu asortymentu na końcowy wynik finansowy przedsiębiorstwa.

Kolejne słupki wykresu oznaczone kolorem zielonym jako wartości dodatnie reprezentują skumulowany wkład takich kategorii jak m.in. Cosmetics, Household, Office Supplies, aż po najmniej dochodowe towary, jakimi są Fruits. Całość zestawienia zamyka niebieski słupek podsumowania końcowego (Suma), dający menedżerom jednoznaczny wgląd w to, które grupy towarowe stanowią główny filar dochodowości hurtowni, a które pełnią jedynie rolę poboczną.



Rysunek 20 Całkowity zysk według rodzaju przedmiotu


5.3 Wielopoziomowy trend czasowy przychodów z hierarchą dat

W celu monitorowania dynamiki sprzedaży w ujęciu historycznym zaimplementowano wykres liniowy obrazujący całkowity przychód według czasu. Dzięki wykorzystaniu wbudowanej w Power BI technologii Drill-down, użytkownik końcowy ma możliwość elastycznego przechodzenia pomiędzy czterema poziomami szczegółowości danych:


- **Poziom roczny (Year):** Prezentuje ogólną makroekonomiczną stabilność przychodów w latach 2010–2016 na poziomie bliskim 180 mld rocznie.

- **Poziom kwartalny (Quarter):** Pozwala dostrzec cykliczne wahania w okresach trzymiesięcznych.
- **Poziom miesięczny (Month):** Służy do identyfikacji wzorców sezonowych.
- **Poziom dzienny (Day):** Oferuje najwyższą granulację danych dla analityków operacyjnych.


Kluczowym wnioskiem płynącym z analizy linii trendu na każdym poziomie agregacji jest gwałtowny, drastyczny spadek przychodów rejestrowany w 2017 roku. Wizualizacja ta doskonale spełnia swoją rolę detekcyjną, alarmując o załamaniu dotychczasowego trendu i stanowiąc punkt wyjścia do głębszej analizy przyczynowo-skutkowej.




Rysunek 21 Całkowity przychód według Roku, Kwartału, Miesiąca i Dnia



Rysunek 22 Całkowity przychód według Roku, Kwartału, Miesiąca



Rysunek 23 Całkowity przychód według Roku, Kwartału




Rysunek 24 Całkowity przychód według Roku

5.4 Wykres punktowy pozycjonowania produktów

Do skorelowania wolumenu sprzedaży z realną zyskownością wdrożono wykres punktowy (Scatter Plot) o tytule ilość sprzedanych sztuk i całkowity zysk ze sprzedaży według rodzaj przedmiotu. Oś pozioma wizualizacji reprezentuje łączną liczbę sprzedanych sztuk, natomiast oś pionowa odzwierciedla generowany zysk całkowity. Wykres ten dzieli asortyment na wyraźne grupy strategiczne:

- **Liderzy marżowi:** Produkty takie jak Cosmetics oraz Household, które mimo standardowego wolumenu sprzedaży plasują się na samej górze osi pionowej, generując najwyższe zyski dla organizacji.
- **Produkty masowe niskomarżowe:** Kategorie takie jak Personal Care czy Beverages, które cechują się najwyższą liczbą sprzedanych sztuk (blisko 418 mln), lecz przynoszą relatywnie niski zysk całkowity.
- **Kategorie krytyczne:** Sektor reprezentowany m.in. przez Fruits, znajdujący się w dolnej części wykresu, oznaczający najniższą efektywność finansową.




Rysunek 25 Całkowity przychód i ilość sprzedanych przedmiotów

5.5 Efektywność operacyjna kanałów dystrybucji

Ostatnim elementem systemu raportowego jest dwuosiowy wykres mieszany (kolumnowo-liniowy) opisujący zależność ilość sprzedanych sztuk i średni zysk według kanału sprzedaży i priorytetu zamówienia.

- **Skala kolumnowa (lewa oś Y):** Przedstawia skumulowany wolumen sprzedaży z podziałem na kanał Offline oraz Online. Każda kolumna została rozbita kolorystycznie (Legenda) na cztery priorytety zamówień (Critical, High, Low, Medium), co pozwala ocenić strukturę ważności transakcji w danym kanale.
- **Skala liniowa (prawa oś Y):** Prezentuje przebieg miary średniego zysku jednostkowego.

Zastosowanie tak skomponowanego wykresu pozwala na jednoczesną ocenę skali operacyjnej (liczby paczek) oraz efektywności finansowej (zysku z jednej transakcji), dostarczając kompletnych informacji do optymalizacji procesów logistycznych przedsiębiorstwa.



Rysunek 26 Analiza według kanału sprzedaży oraz priorytetu zamówienia

6 Eksploracja danych Data Mining

Wdrożenie kluczowych wskaźników efektywności KPI i opartych na nich kokpitów pozwoliło na uzyskanie czytelnego obrazu bieżącej kondycji przedsiębiorstwa, odpowiadając na fundamentalne pytanie: „co się stało?”. Jednak do pełnego zrozumienia mechanizmów rynkowych konieczne jest przejście od klasycznej analityki opisowej do analityki diagnostycznej. Służy temu proces eksploracji danych.

Architektura technologiczna wspierająca procesy Data Mining opiera się na pełnej integracji narzędzi analitycznych firmy Microsoft. Fundamentem dla procesów eksploracyjnych jest warstwa przechowywania danych zrealizowana w środowisku Microsoft SQL Server. Z kolei fundamentalne dla algorytmów zaawansowane modelowanie analityczne zostało zaprojektowane w środowisku Visual Studio 2019 przy użyciu pakietu narzędziowego SQL Server Data Tools, w tym usług analitycznych SSAS.


Do realizacji scenariuszy eksploracyjnych wykorzystano specjalistyczne narzędzia analityczne, w tym między innymi Drzewo Dekompozycji oraz detekcję kluczowych czynników wpływających. Ich zastosowanie ma na celu przeprowadzenie zaawansowanej analizy przyczynowo-skutkowej oraz precyzyjną segmentację produktów. Algorytmy te automatycznie przeszukują miliony rekordów w celu wyłonienia najważniejszych atrybutów (tzw. driverów biznesowych), które w największym stopniu napędzają zysk lub powodują jego spadek. Dzięki wdrożeniu procesów Data Mining, zaprojektowany system Business Intelligence nie tylko monitoruje historyczne wyniki finansowe, ale przede wszystkim dostarcza użytecznej wiedzy

niezbędnej do zrozumienia natury tych wyników i optymalizacji przyszłych działań sprzedażowych.

6.1 Projektowanie wielowymiarowej kostki analitycznej (OLAP)

Fundamentem dla zaawansowanych procesów eksploracji danych oraz błyskawicznego raportowania w środowisku Power BI było wdrożenie wielowymiarowej kostki analitycznej (OLAP). Konstrukcję kostki przeprowadzono w środowisku Visual Studio z wykorzystaniem technologii SQL Server Analysis Services. Głównym celem tego etapu było odejście od powolnych, płaskich zapytań SQL na rzecz pre-agregacji danych, co pozwala na natychmiastowe przeliczanie milionów rekordów z uwzględnieniem wielu płaszczyzn analitycznych jednocześnie.


Centralnym punktem modelu jest tabela faktów fact_Sales, przechowująca kluczowe dane transakcyjne. Została ona powiązana relacyjnie z tabelami wymiarów, takimi jak dim_Location oraz dim_Item, tworząc zoptymalizowany pod kątem wydajności schemat analityczny. Widoczny po lewej stronie panel miar definiuje główne metryki obliczeniowe systemu, obejmujące między innymi całkowity przychód, zysk, wygenerowane koszty oraz wolumen sprzedanych sztuk. Tak skonstruowana i wstępnie zagregowana architektura eliminuje konieczność wykonywania obciążających zapytań bezpośrednio na płaskiej bazie danych. Stanowi ona wysoce wydajny, scentralizowany silnik obliczeniowy, który w czasie rzeczywistym zasila docelową warstwę wizualizacyjną w Power BI oraz buduje rzetelny fundament dla zaimplementowanych algorytmów eksploracji danych.




Rysunek 27 Widok kostki OLAP

6.2 Algorytm drzewa decyzyjnego

Pierwszym zrealizowanym scenariuszem w obszarze eksploracji danych była implementacja modelu predykcyjnego opartego na algorytmie drzew decyzyjnych. Proces ten przeprowadzono w środowisku Visual Studio, z wykorzystaniem usług analitycznych SQL Server Analysis Services. Celem budowy tego modelu było zidentyfikowanie kluczowych produktów transakcyjnych, które w największym stopniu determinują końcową wartość wygenerowanego zysku.




Rysunek 28 Proces tworzenia drzewa decyzyjnego




Rysunek 29 Proces tworzenia drzewa decyzyjnego

Kluczowym etapem konfiguracji było zdefiniowanie ról dla poszczególnych kolumn biorących udział w analizie. W oknie specyfikacji danych treningowych zmienną określającą całkowity zysk (Total Profit) oznaczono jako atrybut przewidywany (Predictable / Target Variable). Z kolei parametry takie jak kategoria produktu (Item Type), priorytet zamówienia (Order Priority), region, kraj oraz kanał sprzedaży (Sales Channel) skonfigurowano jako atrybuty wejściowe (Input). Zadaniem algorytmu było znalezienie matematycznych korelacji między tymi danymi wejściowymi a zyskiem.




Rysunek 30 Proces tworzenia drzewa decyzyjnego

Zgodnie z metodyką uczenia maszynowego, system został skonfigurowany tak, aby losowo podzielić dostępne dane na dwa zbiory. Aż 70% rekordów przeznaczono na zbiór uczący, natomiast pozostałe 30% zarezerwowano jako zbiór testowy. Rezerwacja przestrzeni testowej pozwala na obiektywną weryfikację trafności i dokładności predykcyjnej modelu po jego przetworzeniu, chroniąc system przed zjawiskiem przetrenowania.



Rysunek 31 Proces tworzenia drzewa decyzyjnego

Rezultaty pracy algorytmu zaprezentowano w module Mining Model Viewer za pomocą wizualizacji Microsoft Tree Viewer. Otrzymane drzewo zależności dostarczyło jednoznacznej odpowiedzi analitycznej: głównym, korzeniowym węzłem decyzyjnym (Level 1), warunkującym wartość całkowitego zysku, okazał się rodzaj produktu (Item Type). Algorytm automatycznie dokonał pierwszego podziału zbioru na gałęzie odpowiadające poszczególnym asortymentom (m.in. Snacks, Cosmetics, Meat)




Rysunek 32 Widok drzewa decyzyjnego

6.3 Predykcja finansowa z wykorzystaniem algorytmu szeregów czasowych


Kolejnym etapem w procesie eksploracji danych było wdrożenie modelu analitycznego służącego do prognozowania przyszłych wyników finansowych. W tym celu zaimplementowano algorytm Microsoft Time Series. Jest to wysoce wyspecjalizowane narzędzie, które w swoich strukturach wewnętrznych wykorzystuje zoptymalizowane drzewa regresyjne oraz modele autoregresyjne. Taka kombinacja pozwala na analizę historycznych wzorców, wykrywanie sezonowości oraz przewidywanie przyszłych wartości ciągłych na osi czasu.

Do przetrenowania modelu wykorzystano dedykowaną tabelę raportową Rep_TrendCzasowy. Kolumnę definiującą chronologię zdarzeń (okres analizy) przypisano jako atrybut kluczowy (Key), natomiast zmienną reprezentującą sumę przychodów (Suma Przychodu) oznaczono jako atrybut przewidywany (Predictable).




Rysunek 33 Proces tworzenia szeregu czasowego

Efekt działania zaimplementowanego algorytmu zaprezentowano w module Mining Model Viewer za pomocą widoku wykresu predykcyjnego. Skonstruowana wizualizacja dzieli się na dwie sekcje. Ciągła niebieska linia obrazuje historyczny trend generowanych przychodów, na podstawie którego algorytm uczył się zależności rynkowych. Z kolei przerywana linia, znajdująca się po prawej stronie wykresu (na zaciemnionym tle), reprezentuje wygenerowaną predykcję na pięć kolejnych kroków czasowych w przód (Prediction steps = 5)




Rysunek 34 Proces tworzenia szeregu czasowego



Rysunek 35 Widok szeregu czasowego

6.4 Segmentacja danych z wykorzystaniem algorytmu klastrowania

Kolejnym scenariuszem wdrożonym w projekcie była segmentacja zbioru danych przy użyciu algorytmu Microsoft Clustering. W przeciwieństwie do wcześniej zastosowanych technik predykcyjnych (drzew decyzyjnych oraz regresji czasowej), algorytm klastrowania zalicza się do grupy metod uczenia nienadzorowanego. Oznacza to, że jego celem nie jest zgadywanie z góry zdefiniowanej wartości docelowej, lecz samodzielne odkrywanie ukrytych wzorców oraz kategoryzowanie rekordów w naturalne grupy (klastry) na podstawie podobieństwa wielu atrybutów jednocześnie.



Rysunek 36 Proces tworzenia klastrowania

Proces implementacji modelu przeprowadzono w oparciu o wcześniej zbudowaną wielowymiarową kostkę analityczną (OLAP). Wykorzystanie kostki jako źródła pozwoliło na zastosowanie w modelu skomplikowanych miar wyliczalnych, zdefiniowanych w języku MDX.

W oknie kreatora Data Mining Wizard jako wymiar źródłowy dla analizy wybrano Dim Location . Następnie, aby dostarczyć algorytmowi metryk do porównywania, wprowadzono trzy dodatkowe miary:

- Marza_Zysku – definiującą procentową rentowność
- Srednia_Wartosc_Zamowienia – określającą przychód na pojedynczą transakcję
- Sredni_Zysk_z_Transakcji – wyznaczającą czysty dochód z jednego zamówienia

Name:

Parent Properties

Parent hierarchy:

Parent member:

Expression

W.: 1 Zn.: 53 SPACJE CRLF

Additional Properties

Format string:

Visible:

Non-empty behavior:

Associated measure group:

Display folder:

Color Expressions

Font Expressions

Rysunek 37 Proces tworzenia klastrowania

Name:

Parent Properties

Parent hierarchy:

Parent member:

Expression

W.: 1 Zn.: 59 SPACJE CRLF

Additional Properties

Format string:

Visible:

Non-empty behavior:


Associated measure group:

Display folder:

Color Expressions


Font Expressions

Rysunek 38 Proces tworzenia klastrowania




Rysunek 39 Proces tworzenia klastrowania

Wszystkie powyższe miary, wraz z kluczem lokalizacji oraz podstawowymi miarami całkowitych kosztów i zysków (Total Cost, Total Profit), oznaczono wyłącznie jako atrybuty wejściowe (Input). Świadomie zrezygnowano ze wskazywania zmiennej przewidywanej (Predictable), zmuszając tym samym algorytm do samodzielnego poszukiwania korelacji i grupowania lokalizacji o zbliżonych profilach finansowych.




Rysunek 40 Proces tworzenia s klastrowania



Rysunek 41 Proces tworzenia klastrowania


Wyniki pracy algorytmu zaprezentowano w module Microsoft Cluster Viewer, w zakładce Cluster Diagram. Wygenerowany diagram sieciowy obrazuje dziesięć wyodrębnionych grup (od Cluster 1 do Cluster 10). Każdy węzeł reprezentuje unikalny segment lokalizacji sprzedażowych, posiadających zbliżone parametry marżowe i wolumenowe. Stopień zacieńczenia poszczególnych węzłów wskazuje na gęstość klastra – najciemniejsze węzły (np. Cluster 1 i Cluster 2) skupiają w sobie najwięcej przypadków transakcyjnych z badanej populacji. Grubość i intensywność linii łączących poszczególne klastry definiują siłę podobieństwa między poszczególnymi grupami. Wyizolowanie mniejszych klastrów na obrzeżach sieci (np. Cluster 4, Cluster 9) wskazuje na istnienie niszowych rynków o wysoce specyficznej charakterystyce finansowej, odmiennej od głównego nurtu sprzedaży.



Rysunek 42 Widok klastrowania


6.5 Modelowanie probabilistyczne z wykorzystaniem algorytmu Naive Bayes

Czwartym scenariuszem była analiza probabilistyczna zrealizowana przy pomocy algorytmu Microsoft Naive Bayes. Jest to wydajna technika klasyfikacyjna oparta na matematycznym twierdzeniu Bayesa, służąca do modelowania predykcyjnego. Kluczowym założeniem tego algorytmu jest warunkowa niezależność atrybutów wejściowych względem atrybutu przewidywanego. Z uwagi na specyfikę implementacji w środowisku SQL Server Analysis Services, algorytm ten przyjmuje i przetwarza wyłącznie zmienne o charakterze dyskretnym (lub poddane wcześniejszej dyskretyzacji).




Rysunek 43 Proces tworzenia klasyfikacji Bayes'a

Architektura wejściowa opierała się na przypisaniu odpowiednich ról dla kolumn struktury. Atrybut definiujący typ asortymentu (Item Type) oznaczono jednocześnie jako zmienną wejściową (Input) oraz docelową (Predictable), natomiast unikalny identyfikator (Item ID) posłużył jako klucz struktury. Taka konfiguracja miała na celu zbadanie rozkładu prawdopodobieństw występowania konkretnych typów produktów w relacji do generowanych zjawisk w hurtowni danych.



Rysunek 44 Proces tworzenia klasyfikacji Bayes'a

Aby wyizolować wyłącznie najistotniejsze z biznesowego punktu widzenia relacje, konieczne jest zastosowanie filtrowania i przesunięcie tolerancji wizualizacji w kierunku najsilniejszych powiązań. Oprócz grafu zależności, dogłębna analiza profilowania algorytmu pozwala na zidentyfikowanie charakterystyk atrybutów, co bezpośrednio przekłada się na zdolność systemu do przewidywania, na ile wystąpienie jednego stanu (np. konkretnej kategorii produktu) wpływa na prawdopodobieństwo wystąpienia innych powiązanych czynników rynkowych.




Rysunek 45 Widok klasyfikacji Bayes'a

6.6 Dodatkowe wizualizacje procesów data mining w Power BI

6.6.1 Identyfikacja czynników decydujących o rentowności


Pierwszym wdrożonym komponentem analitycznym w Power BI jest wizualizacja kluczowych czynników wpływających, oparta na algorytmach uczenia maszynowego. Jej zadaniem jest zautomatyzowana detekcja atrybutów, które w największym stopniu napędzają wzrost całkowitego zysku. Wygenerowany model analityczny jednoznacznie wskazuje, że najsilniejszym stymulatorem rentowności jest kategoria sprzedawanego asortymentu. Przeprowadzona analiza wykazuje, że realizacja zamówień z segmentu sprzętu gospodarstwa domowego (Household) podnosi średnią wartość zysku transakcyjnego o ponad 502 tysiące jednostek względem globalnej średniej przedsiębiorstwa, wynoszącej około 352,6 tysiąca. Kolejnymi istotnymi kategoriami napędzającymi dochodowość są kosmetyki ze wzrostem o blisko 499 tysięcy oraz artykuły biurowe. Narzędzie to w pełni automatyzuje zaawansowaną analizę wariancji, błyskawicznie dostarczając kadrze zarządzającej gotowych wniosków na temat najbardziej perspektywicznych sektorów rynkowych.



Rysunek 46 Wizualizacja czynników decydujących

6.6.2 Wielowymiarowa analiza przyczynowo-skutkowa

Drugim narzędziem eksploracyjnym wykorzystanym w środowisku raportowym jest interaktywne Drzewo Dekompozycji. Pozwala ono na dynamiczne rozbięcie zagregowanej miary na wybrane wymiary analityczne przy wsparciu algorytmów sztucznej inteligencji. Punktem wyjścia dla wizualizacji jest globalna suma wygenerowanego zysku, osiągająca pułap 784,5 miliarda jednostek. W pierwszej fazie dekompozycji badaniu poddano kanały dystrybucji, co wykazało wysoką stabilność operacyjną przedsiębiorstwa – zyski z kanału stacjonarnego (Offline) oraz internetowego (Online) rozkładają się niemal symetrycznie, z marginalną przewagą na korzyść sprzedaży tradycyjnej. Dalsze pogłębienie ścieżki analitycznej dla kanału e-commerce pod kątem geograficznym ukazuje wyraźne zróżnicowanie rynków zbytu. Absolutnym fundamentem dochodowości w przestrzeni internetowej okazują się obszary Afryki Subsaharyjskiej oraz Europy, generujące łącznie ponad 203 miliardy zysku i deklasujące pozostałe regiony.



Rysunek 48 Wizualizacja drzewa dekompozycji

7 Kierunki dalszego rozwoju systemu

Zaprojektowana architektura charakteryzuje się wysoką skalowalnością. W celu dostosowania systemu do rosnących wymagań nowoczesnych środowisk korporacyjnych, proces jego rozbudowy można poprowadzić w trzech głównych kierunkach.

Pierwszym z nich jest migracja infrastruktury lokalnej do środowiska chmury obliczeniowej. Przeniesienie procesów integracyjnych oraz hurtowni danych do ekosystemu Microsoft Azure, z wykorzystaniem usług takich jak Azure Data Factory oraz Azure Synapse Analytics, zapewniłoby elastyczność w doborze mocy obliczeniowej. Rozwiązanie to wyeliminowałoby ograniczenia sprzętowe serwera lokalnego w przypadku drastycznego wzrostu wolumenu przetwarzanych danych w przyszłości.

Drugim kierunkiem rozwoju jest zmiana paradygmatu ładowania danych z przetwarzania wsadowego na analitykę czasu rzeczywistego. Zastosowanie mechanizmów strumieniowych pozwoliłoby na ciągłe zasilanie modelu analitycznego spływającymi transakcjami. Dzięki takiemu podejściu kokpity menedżerskie w Power BI mogłyby monitorować wskaźniki KPI z opóźnieniem rzędu zaledwie kilku sekund, co jest krytyczne dla systemów wczesnego ostrzegania o spadkach sprzedaży.

Trzecim i najbardziej zaawansowanym etapem rozbudowy byłoby rozszerzenie modułu Data Mining o dedykowane modele uczenia maszynowego. Ograniczenia standardowych algorytmów wbudowanych w usługę SSAS można wyeliminować poprzez integrację systemu z językami Python lub R. Wdrożenie autorskich skryptów i sieci neuronowych bezpośrednio do struktury Power BI lub wykorzystanie usługi Azure Machine Learning umożliwiłoby m.in. wzbogacenie predykcji finansowych o zewnętrzne czynniki makroekonomiczne czy dynamiczną analizę sentymentu klientów.

8 Podsumowanie

Główne założenie pracy, polegające na budowie kompleksowego systemu klasy Business Intelligence, zostało w pełni zrealizowane na każdym etapie przepływu informacji - od ekstrakcji, przez modelowanie, aż po zaawansowaną eksplorację i wizualizację.

Zastosowanie zautomatyzowanych procesów ETL oraz implementacja relacyjnego modelu gwiazdy pozwoliły na skuteczne scentralizowanie i oczyszczenie miliona rekordów sprzedażowych. Wyeliminowano problem redundancji danych, a zbudowana na tej podstawie wielowymiarowa kostka OLAP stworzyła zoptymalizowane analitycznie środowisko.

Przejsie od klasycznej analityki opisowej do analityki diagnostycznej i predykcyjnej dostarczyło mierzalnych dowodów na użyteczność systemów sztucznej inteligencji

w zarządzaniu przedsiębiorstwem. Wykorzystanie algorytmów takich jak drzewa decyzyjne, klastrowanie czy analiza regresji szeregów czasowych w środowisku SSAS, w połączeniu z wizualizacjami Power BI, pozwoliło na automatyczną detekcję ukrytych wzorców rynkowych. Zaimplementowany system automatyzuje proces wnioskowania przyczynowo-skutkowego i dostarcza precyzyjnych prognoz.